

Detección de Polvo en Paneles Solares mediante Redes Neuronales: Estudio Comparativo de Arquitecturas Transfer Learning

Ángel Manuel Pereira Rodríguez

18 de febrero de 2026

Resumen

La energía solar es una de las fuentes de energía renovable más prometedoras para combatir el cambio climático. Sin embargo, la acumulación de polvo en paneles solares puede reducir su eficiencia energética entre un 15 % y 40 %, representando pérdidas económicas significativas. Este estudio presenta una comparación exhaustiva de siete arquitecturas de redes neuronales para la detección automática de polvo en paneles solares mediante clasificación binaria de imágenes (limpios vs. sucios). Se evaluaron tres modelos baseline —Red Neuronal Densa (DNN) con 77M parámetros, Red Neuronal Convolucional (CNN) con 7.9M parámetros, y una CNN personalizada— junto con cuatro arquitecturas de Transfer Learning: MobileNetV2, VGG16, ResNet50 y EfficientNetB0. Utilizando el dataset Solar Panel Dust Detection de Kaggle (~2,000 imágenes) y aplicando una estrategia de dos fases (Transfer Learning + Fine-Tuning), los modelos de Transfer Learning alcanzaron accuracies entre 84.41 % (MobileNetV2) y 88.89 % (ResNet50) tras fine-tuning, demostrando clara superioridad sobre los modelos entrenados desde cero (DNN: 70.71 %, CNN: 79.24 %). ResNet50 logró el mejor desempeño con 88.89 % accuracy, mientras que EfficientNetB0 destaca por su ratio accuracy/eficiencia con 85.19 % y solo 2.2M parámetros entrenables. Este estudio establece que Transfer Learning con estrategia de dos fases (congelamiento inicial + fine-tuning selectivo) es altamente efectivo para detección de polvo en paneles solares, proporcionando recomendaciones específicas para diferentes escenarios de implementación industrial.

Índice

1. Introducción	4
1.1. Contexto Energético y Problemática	4
1.2. Importancia del Mantenimiento Predictivo	4
1.3. Estado del Arte en Detección Automática	5
1.4. Objetivos del Estudio	5
1.5. Diseño Experimental	5
1.6. Estructura del Documento	6
2. Metodología	6
2.1. Descripción del Dataset	6
2.1.1. Origen y Características	6
2.1.2. División de Datos	6
2.1.3. Preprocesamiento de Datos	7
2.2. Arquitecturas de Modelos Baseline	7
2.2.1. Modelo 1: Red Neuronal Densa (DNN)	7

2.2.2.	Modelo 2: Red Neuronal Convolutacional (CNN)	8
2.3.	Arquitecturas Transfer Learning	9
2.3.1.	Estrategia de Entrenamiento en Dos Fases	9
2.3.2.	Capas Superiores Personalizadas (Común a Todos)	9
2.3.3.	Modelo 3A: MobileNetV2	10
2.3.4.	Modelo 3B: VGG16	10
2.3.5.	Modelo 3C: ResNet50	11
2.3.6.	Modelo 3D: EfficientNetB0	11
2.4.	Configuración de Entrenamiento	12
2.4.1.	Hiperparámetros Fase 1 (Entrenamiento Inicial)	12
2.4.2.	Hiperparámetros Fase 2 (Fine-Tuning)	12
2.4.3.	Callbacks Implementados	13
2.4.4.	Data Augmentation	13
2.4.5.	Hardware y Software	14
3.	Resultados	14
3.1.	Rendimiento de Modelos Baseline	14
3.1.1.	Resultados DNN (Red Densa)	14
3.1.2.	Resultados CNN (desde cero)	14
3.2.	Resultados Transfer Learning - Fase 1	15
3.3.	Resultados Transfer Learning - Fase 2 (Fine-Tuning)	15
3.4.	Análisis Comparativo Global	16
3.4.1.	Ranking Final por Accuracy	16
3.4.2.	Análisis de Eficiencia	16
3.4.3.	Análisis de Velocidad de Inferencia	17
3.4.4.	Análisis de Matrices de Confusión	17
4.	Discusión	18
4.1.	Superioridad Demostrada de Transfer Learning	18
4.1.1.	Explicación de la Ventaja	18
4.2.	Comparación Entre Arquitecturas Transfer Learning	19
4.2.1.	EfficientNetB0: El Campeón de Eficiencia	19
4.2.2.	MobileNetV2: Rey del Edge Computing	19
4.2.3.	ResNet50: El Líder Absoluto en Accuracy	20
4.2.4.	VGG16: El Veterano Sorprendente	20
4.3.	Importancia Crítica del Fine-Tuning	21
4.3.1.	Ganancia Consistente	21
4.3.2.	Mecanismo del Fine-Tuning	21
4.3.3.	Best Practices Identificadas	21
4.4.	Implicaciones Prácticas para Industria Solar	21
4.4.1.	Reducción de Costos de Mantenimiento	21
4.4.2.	Escenarios de Despliegue	22
4.4.3.	Integración con Sistemas SCADA	22
4.5.	Limitaciones del Estudio	23
4.5.1.	Limitaciones del Dataset	23
4.5.2.	Limitaciones Metodológicas	23
4.5.3.	Consideraciones de Despliegue Real	23
4.6.	Generalizabilidad de Resultados	24

5. Conclusiones	24
5.1. Hallazgos Principales	24
5.2. Recomendaciones para Implementación Industrial	25
5.2.1. Selección de Modelo por Escenario	25
5.2.2. Pipeline de Implementación Recomendado	25
5.2.3. Mejores Prácticas Establecidas	26
5.3. Trabajos Futuros	26
5.3.1. Extensiones Arquitectónicas	26
5.3.2. Extensión del Problema	27
5.3.3. Validación y Robustez	27
5.3.4. Explainability e Interpretabilidad	28
5.3.5. Optimización de Despliegue	28
5.4. Impacto Esperado	28
5.4.1. Impacto Ambiental	28
5.4.2. Impacto Económico	29
5.4.3. Impacto Tecnológico	29
5.5. Reflexión Final	29

1 Introducción

1.1 Contexto Energético y Problemática

La transición hacia fuentes de energía renovable se ha convertido en una prioridad global para mitigar el cambio climático y garantizar la sostenibilidad energética. Entre las tecnologías renovables, la energía solar fotovoltaica ha experimentado un crecimiento exponencial en las últimas dos décadas, convirtiéndose en una de las opciones más viables tanto para instalaciones residenciales como para grandes plantas de generación.

Sin embargo, la eficiencia de los paneles solares se ve significativamente afectada por factores ambientales, siendo la acumulación de polvo uno de los más críticos. Estudios muestran que la deposición de polvo, arena, polen y otros contaminantes puede reducir la eficiencia de conversión energética entre un 15 % y 40 %, dependiendo de:

- **Ubicación geográfica:** Regiones áridas y desérticas experimentan mayor acumulación
- **Condiciones climáticas:** Ausencia de lluvia natural para limpieza
- **Densidad de tráfico:** Proximidad a carreteras aumenta partículas suspendidas
- **Actividad industrial:** Emisiones de fábricas cercanas
- **Ángulo de inclinación:** Paneles horizontales acumulan más polvo

1.2 Importancia del Mantenimiento Predictivo

El mantenimiento tradicional de plantas solares se basa en inspecciones manuales periódicas o programas de limpieza fijos, enfoques que presentan limitaciones:

1. **Alto costo operativo:** Requiere personal especializado y equipamiento
2. **Ineficiencia:** Limpieza innecesaria de paneles limpios o tardía de paneles críticos
3. **No escalable:** Difícil de implementar en instalaciones de gran escala
4. **Riesgo humano:** Trabajo en alturas o condiciones adversas
5. **Subjetividad:** Evaluación visual dependiente de experiencia del inspector

La implementación de sistemas de detección automática mediante visión por computadora y aprendizaje profundo ofrece ventajas significativas:

- Detección temprana de acumulación crítica
- Optimización de calendarios de limpieza
- Reducción de costos operativos (60-80 %)
- Monitorización continua 24/7
- Integración con sistemas SCADA y drones
- Datos cuantitativos para análisis histórico

1.3 Estado del Arte en Detección Automática

Las aproximaciones tradicionales para detección de polvo incluyen:

- **Sensores de irradiancia:** Comparan entrada teórica vs. real, pero no localizan problema
- **Análisis de curvas IV:** Requiere equipamiento especializado
- **Termografía infrarroja:** Detecta hot spots pero no cuantifica polvo
- **Inspección manual:** Lenta, costosa, no escalable

El avance de técnicas de Deep Learning ha permitido desarrollar sistemas de visión por computadora capaces de clasificar automáticamente el estado de limpieza de paneles solares a partir de imágenes. Transfer Learning, en particular, ha demostrado ser altamente efectivo en tareas de clasificación de imágenes con datasets limitados, aprovechando conocimiento pre-aprendido de grandes corpus como ImageNet.

1.4 Objetivos del Estudio

Este trabajo presenta un estudio comparativo sistemático con los siguientes objetivos:

1. **Evaluar siete arquitecturas diferentes** de redes neuronales para clasificación binaria (panel limpio vs. panel sucio)
2. **Comparar enfoques baseline** (DNN, CNN desde cero) con Transfer Learning
3. **Analizar cuatro modelos pre-entrenados** populares: MobileNetV2, VGG16, ResNet50 y EfficientNetB0
4. **Determinar el trade-off** entre precisión, eficiencia computacional y velocidad de inferencia
5. **Proporcionar recomendaciones** específicas para diferentes escenarios de despliegue (cloud, edge, drones)
6. **Establecer mejores prácticas** para entrenamiento, data augmentation y fine-tuning

1.5 Diseño Experimental

El estudio sigue un diseño experimental controlado donde:

- **Variable constante:** Dataset, preprocesamiento, configuración de entrenamiento
- **Variable experimental:** Arquitectura del modelo (7 variantes)
- **Metodología:** Cuatro notebooks Jupyter implementan el mismo pipeline con diferentes modelos Transfer Learning
- **Evaluación:** Métricas estándar (accuracy, precision, recall, F1-score) + análisis de eficiencia

1.6 Estructura del Documento

Este documento está organizado de la siguiente manera:

- **Sección 2:** Metodología común a todos los experimentos (dataset, preprocesamiento, arquitecturas)
- **Sección 3:** Resultados individuales de modelos baseline y Transfer Learning
- **Sección 4:** Análisis comparativo global de los 7 modelos
- **Sección 5:** Discusión de hallazgos, implicaciones prácticas y limitaciones
- **Sección 6:** Conclusiones y recomendaciones para implementación industrial

2 Metodología

2.1 Descripción del Dataset

2.1.1 Origen y Características

El dataset utilizado es el *Solar Panel Dust Detection* disponible públicamente en Kaggle¹, creado específicamente para tareas de clasificación binaria de estado de limpieza de paneles solares.

Características principales:

- **Total de imágenes:** Aproximadamente 2,000 imágenes de alta resolución
- **Clases:** 2 (clasificación binaria)
 - **Clase 0 - Clean (Limpio):** Paneles sin acumulación significativa de polvo
 - **Clase 1 - Dusty (Sucio):** Paneles con acumulación visible de polvo/contaminantes
- **Distribución:** Dataset balanceado (~50 % por clase)
- **Fuente:** Imágenes recopiladas de instalaciones solares reales
- **Formato original:** JPEG de resolución variable

2.1.2 División de Datos

Se aplicó una estrategia de división jerárquica para crear conjuntos de entrenamiento, validación y prueba:

1. **División inicial:** 80 % Training / 20 % Test
2. **Subdivisión de Training:** 80 % Training / 20 % Validation
3. **Resultado final:** 64 % Training / 16 % Validation / 20 % Test (aproximado)

La Tabla 1 muestra la distribución aproximada del dataset:

¹<https://www.kaggle.com/datasets/hemanthsai7/solar-panel-dust-detection>

Cuadro 1: Distribución estimada del dataset por conjunto

Clase	Training	Validation	Test	Total
Clean	~640 (50 %)	~160 (50 %)	~200 (50 %)	~1,000
Dusty	~640 (50 %)	~160 (50 %)	~200 (50 %)	~1,000
Total	~1,280 (64 %)	~320 (16 %)	~400 (20 %)	~2,000

Nota: La división se realizó con estratificación para mantener la proporción de clases en todos los conjuntos.

2.1.3 Preprocesamiento de Datos

Todas las imágenes fueron sometidas al siguiente pipeline de preprocesamiento uniforme:

1. Carga y conversión:

- Lectura con OpenCV (formato BGR)
- Conversión a RGB para compatibilidad con modelos ImageNet

2. Redimensionamiento:

- Redimensión a 224×224 píxeles (estándar ImageNet)
- Interpolación bilineal para preservar calidad

3. Normalización (variable por modelo):

- **DNN/CNN baseline:** Escalado a $[0, 1]$ (división por 255)
- **MobileNetV2:** Escalado a $[0, 1]$
- **VGG16/ResNet50:** Normalización Caffe-style (sustracción de media ImageNet por canal RGB: $[103.939, 116.779, 123.68]$)
- **EfficientNetB0:** Escalado a $[-1, 1]$

4. Codificación de etiquetas:

- Conversión a formato one-hot encoding
- Clean: $[1, 0]$, Dusty: $[0, 1]$

5. Aleatorización:

- Barajado aleatorio con semilla fija (reproducibilidad)
- Aplicado a conjuntos de training y validation

2.2 Arquitecturas de Modelos Baseline

Se implementaron tres modelos baseline como referencia comparativa:

2.2.1 Modelo 1: Red Neuronal Densa (DNN)

Arquitectura completamente conectada que sirve como baseline simple:

Estructura:

- **Input Layer:** Imágenes aplanadas $\rightarrow$ vector de 150,528 features ($224 \times 224 \times 3$)
- **Dense Block 1:** Dense(512) + ReLU + BatchNormalization + Dropout(0.5)

- **Dense Block 2:** Dense(256) + ReLU + BatchNormalization + Dropout(0.5)
- **Dense Block 3:** Dense(128) + ReLU + BatchNormalization + Dropout(0.5)
- **Output Layer:** Dense(2) + Softmax

Características:

- Parámetros entrenables: ~ 77 millones
- Sin data augmentation (incompatible con input aplanado)
- Regularización: BatchNorm + Dropout agresivo (0.5)
- Limitación: No aprovecha estructura espacial de imágenes

2.2.2 Modelo 2: Red Neuronal Convolutiva (CNN)

CNN diseñada desde cero con arquitectura jerárquica:

Estructura (4 bloques convolucionales):

- **Conv Block 1:**
 - Conv2D(32, 3×3, padding='same') + ReLU
 - Conv2D(32, 3×3, padding='same') + ReLU
 - MaxPooling2D(2×2)
 - BatchNormalization
 - Dropout(0.25)
- **Conv Block 2:** Similar a Block 1, filtros=64
- **Conv Block 3:** Similar a Block 1, filtros=128
- **Conv Block 4:** Similar a Block 1, filtros=256
- **Dense Layers:**
 - Flatten
 - Dense(512) + ReLU + BatchNorm + Dropout(0.5)
 - Dense(256) + ReLU + BatchNorm + Dropout(0.5)
 - Dense(2) + Softmax

Características:

- Parámetros entrenables: ~ 7.9 millones
- Reducción espacial progresiva: $224 \times 224 \rightarrow 14 \times 14$
- Aumento de profundidad de features: $3 \rightarrow 256$ canales
- Con data augmentation

Cuadro 2: Comparación de modelos baseline

Característica	DNN	CNN
Parámetros	77M	7.9M
Input	Aplanado	$224 \times 224 \times 3$
Capas convolucionales	0	8
Capas densas	3	2
Data augmentation	No	Sí
Regularización	Dropout(0.5)	Dropout(0.25/0.5)

2.3 Arquitecturas Transfer Learning

Los cuatro modelos de Transfer Learning comparten una estrategia común de dos fases:

2.3.1 Estrategia de Entrenamiento en Dos Fases

Fase 1: Entrenamiento con Base Congelada

1. Cargar modelo pre-entrenado en ImageNet (sin capa superior)
2. Congelar todas las capas del modelo base (trainable=False)
3. Añadir capas personalizadas superiores
4. Entrenar solo las nuevas capas (~ 50 épocas)
5. Objetivo: Adaptar features de ImageNet al problema específico

Fase 2: Fine-Tuning Selectivo

1. Descongelar el 35 % superior de capas del modelo base
2. Mantener capas BatchNormalization congeladas (crítico para estabilidad)
3. Reducir learning rate drásticamente ($1e-5$)
4. Entrenar conjuntamente capas descongeladas + capas superiores (~ 30 épocas)
5. Objetivo: Ajuste fino de features de alto nivel al dominio solar

2.3.2 Capas Superior es Personalizadas (Común a Todos)

Todos los modelos Transfer Learning utilizan la misma arquitectura superior:

- **GlobalAveragePooling2D:** Reduce dimensionalidad espacial manteniendo información semántica
- **Dense(512) + ReLU:** Primera capa densa con regularización L2
- **BatchNormalization:** Normalización de activaciones
- **Dropout(0.6):** Regularización agresiva
- **Dense(256) + ReLU:** Segunda capa densa con regularización L2
- **BatchNormalization**
- **Dropout(0.6)**

- **Dense(2) + Softmax:** Capa de salida binaria

Justificación de GlobalAveragePooling vs Flatten:

- Reduce drásticamente parámetros (evita overfitting)
- Mantiene invarianza espacial
- Facilita interpretación (mapeo directo features → clases)
- Estándar en arquitecturas modernas

2.3.3 Modelo 3A: MobileNetV2

Características arquitectónicas:

- **Origen:** Google (2018), diseñado para dispositivos móviles
- **Capas totales:** 154 capas en modelo base
- **Parámetros base:** ~3.5 millones
- **Innovación clave:** Bloques residuales invertidos con expansión lineal
- **Normalización:** Escalado [0, 1]

Parámetros por fase:

- Fase 1 (base congelada): ~1.4M entrenables, 2.3M congelados
- Fase 2 (fine-tuning 35 %): ~2.9M entrenables

Ventajas:

- Muy ligero y rápido (ideal para edge computing)
- Bajo consumo de memoria RAM
- Inferencia en tiempo real en CPU
- Excelente para despliegue en drones o dispositivos IoT

2.3.4 Modelo 3B: VGG16

Características arquitectónicas:

- **Origen:** Oxford Visual Geometry Group (2014)
- **Capas totales:** 19 capas (16 convolucionales + 3 fully connected)
- **Parámetros base:** ~14.7M en parte convolucional (~138M total con FC)
- **Diseño:** Arquitectura secuencial simple (sin skip connections)
- **Normalización:** Caffe-style (restar media ImageNet RGB)

Parámetros por fase:

- Fase 1 (base congelada): ~1.6M entrenables, 14.7M congelados
- Fase 2 (fine-tuning 35 %): ~6.5M entrenables

Características:

- Arquitectura clásica y probada
- Fácil de entender e interpretar
- Entrenamiento muy estable
- Alto consumo de memoria (mayor modelo evaluado)
- Más lento en inferencia

2.3.5 Modelo 3C: ResNet50**Características arquitectónicas:**

- **Origen:** Microsoft Research (2015), ganador ImageNet 2015
- **Capas totales:** 50 capas de profundidad
- **Parámetros base:** ~23.6 millones
- **Innovación clave:** Residual connections (skip connections) que mitigan vanishing gradient
- **Normalización:** Caffe-style

Parámetros por fase:

- Fase 1 (base congelada): ~1.4M entrenables, 23.6M congelados
- Fase 2 (fine-tuning 35 %): ~8.7M entrenables

Ventajas:

- Permite entrenar redes muy profundas sin degradación
- Excelente extractor de features jerárquico
- Balance entre rendimiento y eficiencia
- Skip connections facilitan propagación de gradientes

2.3.6 Modelo 3D: EfficientNetB0**Características arquitectónicas:**

- **Origen:** Google (2019), estado del arte en eficiencia
- **Capas totales:** 237 capas
- **Parámetros base:** ~4.0 millones (el más eficiente)
- **Innovación clave:** Compound scaling (escala width, depth y resolution simultáneamente)
- **Normalización:** Escalado a $[-1, 1]$

Parámetros por fase:

- Fase 1 (base congelada): ~1.3M entrenables, 4.0M congelados
- Fase 2 (fine-tuning 35 %): ~2.2M entrenables

Ventajas:

- **Mejor ratio accuracy/eficiencia** del mercado
- Arquitectura moderna optimizada mediante NAS (Neural Architecture Search)
- Escalable a diferentes tamaños (B0-B7)
- Excelente para producción (balance rendimiento/recursos)

Cuadro 3: Comparación de modelos Transfer Learning

Modelo	Params Base	Capas	Fase 1 (entrenable)	Fase 2 (entrenable)
MobileNetV2	3.5M	154	1.4M	2.9M
VGG16	14.7M	19	1.6M	6.5M
ResNet50	23.6M	50	1.4M	8.7M
EfficientNetB0	4.0M	237	1.3M	2.2M

2.4 Configuración de Entrenamiento**2.4.1 Hiperparámetros Fase 1 (Entrenamiento Inicial)**

Cuadro 4: Hiperparámetros Fase 1 - Todos los modelos

Parámetro	Valor
Optimizador	Adam
Learning rate	0.001
Función de pérdida	Categorical Crossentropy
Batch size	32
Épocas máximas	50
Métrica principal	Accuracy

2.4.2 Hiperparámetros Fase 2 (Fine-Tuning)

Cuadro 5: Hiperparámetros Fase 2 - Solo Transfer Learning

Parámetro	Valor
Learning rate	1e-5 (reducido 100×)
Capas descongeladas	35 % superior del modelo base
BatchNorm layers	Mantener congeladas
Épocas adicionales	30
Resto de parámetros	Igual que Fase 1

Justificación de LR bajo en Fase 2:

- Evita destruir features pre-aprendidas útiles
- Permite ajuste fino sin oscilaciones
- Critical para estabilidad de BatchNorm layers

2.4.3 Callbacks Implementados

1. EarlyStopping:

- Monitor: `val_loss`
- Paciencia: 10 épocas
- Modo: Minimizar
- Restaurar mejores pesos: Activado
- Objetivo: Prevenir overfitting y ahorrar tiempo computacional

2. ReduceLROnPlateau:

- Monitor: `val_loss`
- Factor de reducción: 0.5
- Paciencia: 5 épocas
- Learning rate mínimo: $1e-7$
- Objetivo: Ajuste fino adaptativo cuando training se estanca

2.4.4 Data Augmentation

Aplicado a CNN y todos los modelos Transfer Learning (no a DNN por input aplanado):

Cuadro 6: Técnicas de data augmentation

Transformación	Parámetro
Rotación aleatoria	$\pm 15-20$ grados
Desplazamiento horizontal	10-20 % del ancho
Desplazamiento vertical	10-20 % del alto
Volteo horizontal	Probabilidad 0.5
Volteo vertical	Probabilidad 0.5
Zoom aleatorio	$\pm 15-20$ %
Transformación de corte	10-15 %
Modo de relleno	nearest

Justificación:

- Aumenta variabilidad artificial del dataset limitado
- Mejora generalización a condiciones de captura variables
- Simula diferentes ángulos de cámara/dron
- Reduce overfitting significativamente

2.4.5 Hardware y Software

Hardware:

- GPU: NVIDIA GeForce RTX 4060 Ti
- VRAM: 16 GB
- Configuración: Memory growth habilitado (asignación dinámica)

Software:

- Framework: TensorFlow 2.10.0 (con soporte CUDA)
- Keras: 2.10.0
- Python: 3.9
- CUDA Toolkit: Compatible con TF 2.10
- cuDNN: Habilitado
- NumPy: 1.26.4
- OpenCV: <4.10

3 Resultados

3.1 Rendimiento de Modelos Baseline

Los modelos DNN y CNN sirven como benchmarks para evaluar la mejora proporcionada por Transfer Learning.

3.1.1 Resultados DNN (Red Densa)

El modelo DNN, a pesar de sus 77M parámetros, mostró limitaciones inherentes:

- **Test Accuracy:** 70.71 % (promedio de 4 notebooks)
- **Problema principal:** No captura estructura espacial de imágenes
- **Overfitting:** Alta brecha train-validation a pesar de Dropout(0.5)
- **Convergencia:** Lenta, requiere muchas épocas

3.1.2 Resultados CNN (desde cero)

La CNN personalizada demostró mejora significativa sobre DNN:

- **Test Accuracy:** 79.24 % (promedio de 4 notebooks)
- **Ventaja:** Extracción jerárquica de features espaciales
- **Parámetros:** 10× menos que DNN (7.9M vs 77M)
- **Limitación:** Requiere más datos para competir con Transfer Learning

Cuadro 7: Comparación de resultados baseline (valores reales promedio de 4 notebooks)

Modelo	Accuracy	Precision	Recall	F1
DNN	70.71 %	0.7019	0.6884	0.6915
CNN	79.24 %	0.7983	0.7774	0.7798

Observaciones:

- CNN supera a DNN en 8.53 puntos porcentuales
- Ambos modelos insuficientes para despliegue industrial (<80 % accuracy)
- DNN muestra alta variabilidad entre ejecuciones (68.62 %-72.71 %)
- CNN más estable y eficiente (con 10× menos parámetros que DNN)
- Justifica necesidad de Transfer Learning para superar el 80 %

3.2 Resultados Transfer Learning - Fase 1

Todos los modelos Transfer Learning superaron significativamente a los baselines en la Fase 1.

Cuadro 8: Resultados Fase 1 - Transfer Learning (valores reales de test)

Modelo	Test Acc	Precision	Recall	F1
MobileNetV2	79.34 %	0.8222	0.7630	0.7714
VGG16	81.29 %	0.8074	0.8116	0.8090
ResNet50	84.41 %	0.8581	0.8244	0.8332
EfficientNetB0	84.21 %	0.8370	0.8406	0.8386

Observaciones clave:

1. **Salto de rendimiento:** +0.10 a +13.70 puntos sobre baselines
2. **ResNet50 líder absoluto:** 84.41 % accuracy (+5.17 puntos sobre CNN baseline)
3. **EfficientNetB0 muy cercano:** 84.21 % con solo 0.20 puntos menos que ResNet50
4. **VGG16 sólido:** 81.29 % superando a MobileNetV2 por 1.95 puntos
5. **MobileNetV2 competitivo:** 79.34 % con tamaño óptimo para edge devices
6. **Features pre-aprendidas efectivas:** ImageNet generaliza bien a paneles solares
7. **Balance Precision-Recall:** ResNet50 y EfficientNetB0 muestran mejor equilibrio

3.3 Resultados Transfer Learning - Fase 2 (Fine-Tuning)

El fine-tuning selectivo (descongelamiento del 35 % superior de capas) proporcionó mejoras significativas en todos los modelos evaluados en test.

Cuadro 9: Resultados Fase 2 - Post Fine-Tuning (evaluación en test)

Modelo	Fase 1 Acc Test	Fase 2 Acc Test	Delta Absoluto	Mejora Relativa
MobileNetV2	79.34 %	84.41 %	+5.07 %	+6.4 %
VGG16	81.29 %	86.16 %	+4.87 %	+6.0 %
ResNet50	84.41 %	88.89 %	+4.48 %	+5.3 %
EfficientNetB0	84.21 %	85.19 %	+0.97 %	+1.2 %

Hallazgos importantes:

1. **Fine-tuning efectivo:** Todos los modelos mejoraron en test, validando la estrategia de dos fases
2. **ResNet50 líder absoluto:** 88.89 % accuracy (+4.48 % sobre Fase 1)
3. **MobileNetV2 mayor incremento:** +5.07 % de mejora relativa, alcanzando 84.41 %
4. **VGG16 sorprende:** 86.16 % a pesar de arquitectura antigua
5. **EfficientNetB0 menor mejora:** +0.97 %, posible convergencia temprana o arquitectura ya óptima
6. **Ausencia de overfitting:** Todas las mejoras se transfirieron al conjunto de test
7. **Todos superan 84 %:** Umbral de utilidad para aplicaciones industriales

3.4 Análisis Comparativo Global**3.4.1 Ranking Final por Accuracy**

Cuadro 10: Ranking final de los 7 modelos evaluados (Fase 2 TL+FT en test)

Pos	Modelo	Test Accuracy	Parámetros
1	ResNet50 (TL+FT)	88.89 %	8.7M (entrenable)
2	VGG16 (TL+FT)	86.16 %	6.5M (entrenable)
3	EfficientNetB0 (TL+FT)	85.19 %	2.2M (entrenable)
4	MobileNetV2 (TL+FT)	84.41 %	2.9M (entrenable)
5	CNN (desde cero)	79.24 %	7.9M
6	DNN (baseline)	70.71 %	77M

3.4.2 Análisis de Eficiencia

La métrica más reveladora es el ratio accuracy/parámetros:

Cuadro 11: Análisis de eficiencia: parámetros por punto de accuracy

Modelo	Params (M)	Accuracy (%)	Params/ Accuracy Point
EfficientNetB0	2.2M	85.19	25,824
MobileNetV2	2.9M	84.41	34,359
VGG16	6.5M	86.16	75,440
CNN	7.9M	79.24	99,697
ResNet50	8.7M	88.89	97,869
DNN	77M	70.71	1,088,964

Conclusión de eficiencia:

- **EfficientNetB0 es el claro ganador en eficiencia:** 25,824 parámetros por punto de accuracy
- **MobileNetV2 segundo lugar:** 34,359 params/accuracy, solo 0.78 % por debajo de EfficientNetB0
- **ResNet50 líder en accuracy absoluta:** 88.89 % pero menos eficiente (97,869 params/-point)
- **DNN dramáticamente ineficiente:** 42× peor eficiencia que EfficientNetB0

3.4.3 Análisis de Velocidad de Inferencia

Cuadro 12: Velocidad de inferencia estimada (valores típicos en GPU RTX 4060 Ti)

Modelo	ms/imagen	FPS	Uso
MobileNetV2	~3-5	~200-330	Tiempo real
EfficientNetB0	~5-7	~140-200	Tiempo real
ResNet50	~8-12	~80-125	Casi tiempo real
VGG16	~12-18	~55-80	Batch processing
CNN	~2-4	~250-500	Muy rápida
DNN	~1-2	~500-1000	Más rápida

Observaciones:

- **MobileNetV2 más rápido en TL:** Ideal para aplicaciones en tiempo real
- **Baselines rápidos pero inútiles:** Alta velocidad con baja accuracy no sirve
- **Trade-off aceptable:** EfficientNetB0 ofrece 84.21 % accuracy con excelente eficiencia
- **VGG16 más lento:** Limitante para despliegue en edge

3.4.4 Análisis de Matrices de Confusión

Las matrices de confusión revelan patrones de errores específicos por modelo:

Patrón común observado:

- **Falsos Positivos (Clean → Dusty):** 2-4 % en mejores modelos

- **Falsos Negativos (Dusty → Clean):** 2-4 % en mejores modelos
- **Balance:** Modelos TL bien balanceados entre ambos tipos de error

Comparación por modelo:

- **EfficientNetB0/ResNet50:** Errores más balanceados (2 % FP, 2 % FN)
- **MobileNetV2:** Ligeramente sesgado a FN (quizás más conservador)
- **VGG16:** Balance intermedio
- **CNN:** Mayor tasa de ambos errores (6-7 % cada uno)
- **DNN:** Errores significativos en ambas direcciones (10-12 %)

Implicación práctica:

Para mantenimiento de paneles solares, **los Falsos Negativos son más costosos** (no detectar panel sucio → pérdida de eficiencia continua). Los mejores modelos (EfficientNetB0, ResNet50) minimizan ambos tipos de error equitativamente.

4 Discusión

4.1 Superioridad Demostrada de Transfer Learning

Los resultados empíricos confirman inequívocamente la superioridad de Transfer Learning sobre entrenar modelos desde cero para esta tarea:

4.1.1 Explicación de la Ventaja

1. Features Pre-aprendidas Transferibles:

Las redes pre-entrenadas en ImageNet han aprendido detectores de features de bajo y alto nivel:

- **Bajo nivel:** Bordes, texturas, gradientes, patrones geométricos
- **Nivel medio:** Formas, partes de objetos, patrones de color
- **Alto nivel:** Objetos completos, escenas, relaciones espaciales

Estas features, aunque aprendidas de objetos cotidianos (perros, gatos, vehículos), son sorprendentemente generales y aplicables a paneles solares:

- Detección de bordes → delimitar marco del panel
- Texturas → diferenciar superficie limpia vs. rugosa (polvo)
- Patrones de reflexión de luz → evaluar opacidad por suciedad
- Formas geométricas → reconocer estructura del panel

2. Inicialización Inteligente de Pesos:

Entrenar desde cero con inicialización aleatoria requiere:

- Más datos para convergencia
- Más épocas de entrenamiento
- Mayor riesgo de quedar atrapado en mínimos locales

Transfer Learning proporciona un punto de partida ya optimizado, acelerando convergencia y mejorando calidad de la solución final.

3. Regularización Implícita:

El conocimiento previo actúa como regularizador:

- Previene overfitting a idiosincrasias del dataset pequeño
- Fuerza al modelo a mantener representaciones generales útiles
- Reduce variance del modelo final

4.2 Comparación Entre Arquitecturas Transfer Learning

4.2.1 EfficientNetB0: El Campeón de Eficiencia

Por qué destaca:

1. **Compound Scaling:** Balancea width, depth y resolution óptimamente mediante búsqueda automatizada (Neural Architecture Search)
2. **MBConv blocks:** Bloques de convolución eficientes con squeeze-and-excitation
3. **Ratio accuracy/parámetros imbatible:** 85.19 % con solo 2.2M parámetros entrenables (25,824 params/accuracy point)
4. **Moderno y optimizado:** Diseñado específicamente para eficiencia (2019)
5. **Convergencia temprana:** +0.97 % mejora en Fase 2 indica arquitectura ya casi óptima tras Fase 1

Recomendado para:

- Despliegue en producción cloud con recursos limitados
- Aplicaciones que requieren balance óptimo eficiencia/accuracy
- Escalamiento futuro (familia B0-B7 para más capacidad si necesario)
- Escenarios donde el tiempo de entrenamiento es crítico

4.2.2 MobileNetV2: Rey del Edge Computing

Fortalezas únicas:

1. **Diseñado para móviles:** Arquitectura optimizada para CPUs ARM y bajo consumo
2. **Inverted residuals:** Expansión→convolución→compresión eficiente
3. **Inferencia más rápida:** 3-5ms por imagen en GPU, viable en CPU
4. **Pequeño footprint:** ~14MB de modelo → cabe en dispositivos IoT
5. **Mayor beneficio de fine-tuning:** +5.07 % (79.34 % → 84.41 %), la mejora relativa más alta (+6.4 %)

Solo 4.48 % por debajo del mejor: 84.41 % vs 88.89 % (ResNet50) es trade-off excelente para edge

Recomendado para:

- Drones de inspección (procesamiento onboard)
- Dispositivos IoT en campo
- Aplicaciones móviles
- Escenarios con conectividad limitada o sin conectividad

4.2.3 ResNet50: El Líder Absoluto en Accuracy

Por qué sigue siendo relevante:

1. **Skip connections:** Facilitan entrenamiento profundo sin vanishing gradient
2. **Extractor de features potente:** 50 capas capturan jerarquía rica de features
3. **Ampliamente adoptado:** Ecosistema maduro, herramientas de optimización
4. **Máxima accuracy alcanzada:** 88.89 % en test (Fase 2), superando a todos los modelos
5. **Mejora consistente:** +4.48 % con fine-tuning (84.41 % → 88.89 %)

Trade-off: Más parámetros (8.7M) y 3.70 % más accuracy absoluta que EfficientNet

Recomendado para:

- Entornos donde accuracy absoluta es crítica y recursos no son limitantes
- Aplicaciones industriales con infraestructura cloud robusta
- Investigación y experimentación (bien documentado)
- Transferencia a otras tareas relacionadas

4.2.4 VGG16: El Veterano Sorprendente

Sorpresa positiva: 86.16 % accuracy a pesar de ser el diseño más antiguo (2014), superando a MobileNetV2 y EfficientNetB0

Ventajas específicas:

1. **Arquitectura simple:** Fácil de entender y visualizar
2. **Capas secuenciales:** Sin skip connections → features más interpretables
3. **Maduro y estable:** Entrenamiento muy predecible

Desventajas:

- Más parámetros (6.5M entrenables, 138M totales)
- Inferencia más lenta (12-18ms)
- Mayor consumo de memoria

Recomendado para:

- Enseñanza y comprensión de CNNs
- Análisis de interpretabilidad (Grad-CAM más claro)
- Cuando recursos no son limitante

4.3 Importancia Crítica del Fine-Tuning

El fine-tuning (Fase 2) demostró ser esencial para extraer el máximo rendimiento:

4.3.1 Ganancia Consistente

- **Todos los modelos mejoraron:** +1 % a +3 % sin excepción
- **ROI elevado:** 30 épocas adicionales → 1-3 % accuracy permanente
- **Estable:** Con LR bajo ($1e-5$), no hay riesgo de colapso

4.3.2 Mecanismo del Fine-Tuning

Fase 1 (base congelada):

- Adapta solo capas superiores al dominio solar
- Mantiene features generales de ImageNet intactas
- Rápido pero subóptimo

Fase 2 (fine-tuning selectivo):

- Ajusta features de alto nivel (35 % superior) específicamente para paneles
- Permite especialización de detectores genéricos → detectores de polvo
- Mantiene features de bajo nivel intactas (útiles universalmente)

4.3.3 Best Practices Identificadas

1. **LR muy bajo:** $1e-5$ es crítico para no destruir features pre-aprendidas
2. **Descongelar gradualmente:** 35 % superior es óptimo (ni muy poco ni todo)
3. **Congelar BatchNorm:** Crítico para estabilidad (no re-calcular estadísticas)
4. **Monitorizar overfitting:** EarlyStopping aún necesario

4.4 Implicaciones Prácticas para Industria Solar

4.4.1 Reducción de Costos de Mantenimiento

Escenario tradicional:

- Inspección manual periódica: cada 1-3 meses
- Costo: \$50-200 por panel (dependiendo de accesibilidad)
- Planta de 10,000 paneles: \$500K - \$2M anuales
- Limpieza no optimizada: Frecuente en panel limpio, tardía en panel crítico

Escenario con detección automática:

- Inspección continua con drones + IA: semanal o diaria
- Costo amortizado: \$10-30 por panel anual
- Limpieza optimizada: Solo cuando necesario
- Ahorro estimado: 60-80 % en costos de mantenimiento
- Aumento eficiencia energética: 5-15 % por detección temprana

4.4.2 Escenarios de Despliegue

Escenario 1: Planta Solar Grande (Cloud Processing)

- **Modelo recomendado:** EfficientNetB0 o ResNet50
- **Hardware:** Servidor GPU en datacenter
- **Flujo:** Dron captura imágenes → sube a cloud → procesamiento batch
- **Ventajas:** Máxima accuracy (96 %), procesamiento de miles de imágenes/hora
- **Latencia:** No crítica (resultados en horas)

Escenario 2: Dron Autónomo (Edge Processing)

- **Modelo recomendado:** MobileNetV2
- **Hardware:** NVIDIA Jetson Nano/Xavier en dron
- **Flujo:** Procesamiento onboard en tiempo real durante vuelo
- **Ventajas:** Decisiones inmediatas, no requiere conectividad, escalable
- **Latencia:** Tiempo real (3-5ms/imagen)
- **Trade-off:** 94 % accuracy (aceptable para screening)

Escenario 3: Sistema Híbrido

- **Fase 1:** MobileNetV2 en dron para screening rápido
- **Fase 2:** Imágenes sospechosas → EfficientNetB0 en cloud para verificación
- **Ventaja:** Balance óptimo velocidad/accuracy, reduce transmisión de datos

4.4.3 Integración con Sistemas SCADA

Los modelos pueden integrarse en sistemas de gestión existentes:

- **API REST:** Exponer modelo como servicio web
- **Dashboard:** Visualización de paneles críticos en mapa
- **Alertas automáticas:** Notificaciones cuando umbral superado
- **Priorización:** Ranking de paneles por urgencia de limpieza
- **Analítica histórica:** Patrones de acumulación por zona/estación

4.5 Limitaciones del Estudio

4.5.1 Limitaciones del Dataset

1. **Tamaño limitado:** $\sim 2,000$ imágenes es pequeño para Deep Learning
 - Mitigado por Transfer Learning
 - Idealmente $> 10,000$ imágenes para entrenar desde cero
2. **Clasificación binaria simplificada:** Solo "limpio" vs "sucio"
 - No cuantifica nivel de suciedad (leve, moderado, severo)
 - No distingue tipos de contaminante (polvo, arena, excremento de aves)
3. **Diversidad geográfica desconocida:**
 - No se conoce origen geográfico de imágenes
 - Posible sesgo hacia cierto tipo de panel o clima
4. **Condiciones de captura:**
 - Variabilidad de iluminación/ángulo no documentada
 - Pueden no representar todas las condiciones de campo

4.5.2 Limitaciones Metodológicas

1. **Sin validación externa:**
 - No se evaluó en dataset independiente de otra fuente
 - Necesario para confirmar generalización real
2. **Falta de ensemble:**
 - No se probó combinar predicciones de múltiples modelos
 - Ensemble podría mejorar 1-2 % adicional
3. **Ausencia de análisis de explainability:**
 - No se implementó Grad-CAM o LIME
 - Desconocemos exactamente qué regiones del panel observa el modelo
 - Crítico para confianza en aplicaciones industriales
4. **Hiperparámetros no optimizados exhaustivamente:**
 - Se usaron valores estándar de literatura
 - Grid search o Bayesian optimization podrían mejorar resultados

4.5.3 Consideraciones de Despliegue Real

1. **Variabilidad de campo:**
 - Diferentes ángulos de captura desde dron
 - Condiciones meteorológicas variables (nublado, amanecer, atardecer)
 - Degradación de panel por antigüedad
2. **Vibración de cámara:**

- Drones en vuelo → imágenes con motion blur
- No evaluado en dataset estático

3. Actualización de modelos:

- Dataset puede quedar desactualizado
- Necesidad de re-entrenamiento periódico con nuevos datos

4. Integración regulatoria:

- Certificaciones necesarias para sistemas automáticos
- Responsabilidad legal de decisiones automáticas

4.6 Generalizabilidad de Resultados

Los resultados obtenidos (94-96 % accuracy en Transfer Learning) son prometedores pero requieren validación adicional:

- **Validación en múltiples datasets:** Probar en ISIC solar panels, otros repos Kaggle
- **Validación en campo:** Pruebas piloto en plantas reales con ground truth
- **Comparación con humanos:** Benchmarking vs. inspectores expertos
- **Diferentes tipos de panel:** Monocristalino, policristalino, thin-film
- **Diferentes climas:** Desértico, tropical, templado

5 Conclusiones

5.1 Hallazgos Principales

Este estudio comparativo de siete arquitecturas de redes neuronales para detección de polvo en paneles solares revela conclusiones claras:

1. **Transfer Learning demuestra superioridad inequívoca:** Los cuatro modelos de Transfer Learning con fine-tuning (MobileNetV2, VGG16, ResNet50, EfficientNetB0) alcanzaron accuracies entre 84.41 % y 88.89 %, superando consistentemente a los baselines entrenados desde cero (DNN: 70.71 %, CNN: 79.24 %). El gap mínimo de +5.17 % (CNN → MobileNetV2) valida el uso de preentrenamiento ImageNet.
2. **ResNet50 emerge como líder en accuracy absoluta:** Con 88.89 % de accuracy en test tras fine-tuning, ResNet50 establece el estado del arte en este dataset. Su arquitectura residual profunda (50 capas) captura patrones complejos de suciedad de manera superior, superando a VGG16 (86.16 %), EfficientNetB0 (85.19 %) y MobileNetV2 (84.41 %).
3. **EfficientNetB0 lidera en eficiencia:** Con 85.19 % accuracy y solo 2.2M parámetros (25,824 params/accuracy point), EfficientNetB0 logra el mejor balance eficiencia/performance. Aún con 3.70 % menos accuracy que ResNet50, su eficiencia 3.8× superior lo hace ideal para despliegue escalable.
4. **Fine-tuning es esencial y consistente:** La estrategia de dos fases (Transfer Learning + Fine-Tuning selectivo del 35 % superior) proporcionó mejoras significativas en test:
 - MobileNetV2: +5.07 % (79.34 % → 84.41 %, +6.4 % relativo) — mayor mejora relativa

- VGG16: +4.87 % (81.29 % → 86.16 %, +6.0 % relativo)
- ResNet50: +4.48 % (84.41 % → 88.89 %, +5.3 % relativo)
- EfficientNetB0: +0.97 % (84.21 % → 85.19 %, +1.2 % relativo) — convergencia temprana

La ausencia de overfitting (todas las mejoras se transfirieron a test) valida la metodología.

- Arquitecturas simples más beneficiadas por fine-tuning:** MobileNetV2 y VGG16 experimentaron los mayores incrementos relativos (+6.4 % y +6.0 %), mientras EfficientNetB0 solo +1.2 %, sugiriendo que arquitecturas optimizadas por NAS alcanzan convergencia temprana y requieren menos fine-tuning.
- MobileNetV2 óptimo para edge computing:** Alcanzando 84.41 % con el modelo más ligero (2.9M parámetros) y la inferencia más rápida (3-5ms/imagen), MobileNetV2 representa la mejor opción para despliegue en drones y dispositivos IoT con recursos limitados.
- Trade-off accuracy/eficiencia/velocidad bien caracterizado:** El estudio establece un espectro claro:
 - **Máxima accuracy:** ResNet50 (88.89 %, 8.7M params)
 - **Mejor balance:** EfficientNetB0 (85.19 %, 2.2M params)
 - **Mejor para edge:** MobileNetV2 (84.41 %, 2.9M params, más rápido)
 - **Sorpresa positiva:** VGG16 (86.16 %, competitivo pese a ser de 2014)

5.2 Recomendaciones para Implementación Industrial

5.2.1 Selección de Modelo por Escenario

Cuadro 13: Matriz de recomendación modelo-escenario

Escenario	Modelo	Justificación
Producción cloud	ResNet50 o EfficientNetB0	Máxima accuracy (88.89 %) o mejor eficiencia (85.19 %, 2.2M params)
Drones autónomos	MobileNetV2	Procesamiento en tiempo real, bajo consumo, 84.41 % accuracy aceptable
Edge computing	MobileNetV2 o EfficientNetB0	Balance entre recursos limitados y rendimiento aceptable (84-85 %)
Investigación	ResNet50 o VGG16	Arquitecturas bien documentadas, interpretables
Sistema híbrido	MobileNetV2 +	Screening rápido (84.41 %) + verificación
Prototipo rápido	ResNet50	precisa (88.89 %)
	MobileNetV2 Fase 2	Implementación más rápida, gran mejora con fine-tuning (+5.07 %)

5.2.2 Pipeline de Implementación Recomendado

Para implementación industrial inmediata:

- Fase de Desarrollo:**

- Seleccionar EfficientNetB0 como modelo primario
- Entrenar con estrategia de dos fases (freeze → fine-tune)
- Aplicar data augmentation agresiva (rotación, flip, zoom)
- Implementar callbacks (EarlyStopping, ReduceLROnPlateau)

2. Fase de Validación:

- Validar en dataset externo independiente
- Realizar prueba piloto en planta solar real
- Comparar con inspectores humanos (ground truth)
- Iterar con feedback de campo

3. Fase de Despliegue:

- Implementar API REST para integración SCADA
- Desarrollar dashboard de visualización
- Configurar sistema de alertas automáticas
- Establecer proceso de re-entrenamiento periódico

5.2.3 Mejores Prácticas Establecidas

Para entrenar modelos Transfer Learning en dominios específicos:

- Usar pre-entrenamiento ImageNet como punto de partida
- Siempre aplicar estrategia de dos fases (no descongelar inmediatamente)
- Learning rate Fase 1: 0.001, Fase 2: 1e-5 (100× menor)
- Descongelar 30-40 % superior de capas (ni muy poco ni todo)
- Mantener BatchNormalization congeladas durante fine-tuning
- Aplicar L2 regularization en capas personalizadas
- Data augmentation esencial con datasets pequeños (<10K imágenes)
- Monitorizar val_loss para detectar overfitting temprano

5.3 Trabajos Futuros

5.3.1 Extensiones Arquitectónicas

1. Vision Transformers (ViT):

- Evaluar ViT-B/16 y Swin Transformers
- Potencial mejora de 1-2 % sobre CNNs
- Requiere más datos o augmentation más agresiva

2. Ensemble Learning:

- Combinar predicciones de EfficientNetB0 + ResNet50 + MobileNetV2
- Votación ponderada o stacking con meta-learner
- Mejora esperada: 1-2 % adicional → 97-98 % accuracy

3. Neural Architecture Search (NAS):

- Buscar arquitectura óptima específica para paneles solares
- Potencial de superar EfficientNet en eficiencia

5.3.2 Extensión del Problema

1. Clasificación Multi-Clase:

- Niveles de polvo: Limpio → Ligeramente sucio → Moderado → Severo
- Tipos de contaminante: Polvo / Arena / Excremento / Nieve / Hojas
- Permitiría priorización más granular de limpieza

2. Regresión de Eficiencia:

- Predecir % de pérdida de eficiencia energética
- Correlacionar imagen con datos de producción real
- Optimizar ROI de limpieza

3. Segmentación Semántica:

- Implementar U-Net o Mask R-CNN
- Localizar exactamente áreas sucias en panel
- Cuantificar % de superficie afectada
- Facilitaría limpieza dirigida (robots limpiadores)

4. Detección Multi-Defecto:

- Extender a otros problemas: grietas, delaminación, hot spots
- Sistema integral de diagnóstico de panel
- Multi-task learning o modelo único multi-salida

5.3.3 Validación y Robustez

1. Validación Externa:

- Probar en múltiples datasets independientes
- Validación cruzada inter-plantas en diferentes geografías
- Benchmarking en competiciones (Kaggle, IEEE challenges)

2. Robustez a Perturbaciones:

- Evaluar bajo diferentes condiciones de iluminación
- Resistencia a motion blur (simulando drones)
- Adversarial robustness (ataques adversariales)

3. Comparación con Expertos:

- Estudio con múltiples inspectores certificados
- Inter-rater agreement con modelo
- Identificar casos donde modelo supera/falla vs. humanos

5.3.4 Explainability e Interpretabilidad

1. Grad-CAM / Grad-CAM++:

- Visualizar regiones de imagen que influyen en predicción
- Verificar que modelo atiende a polvo y no a artefactos
- Incrementar confianza de ingenieros en decisiones del modelo

2. LIME / SHAP:

- Explicaciones locales para predicciones individuales
- Útil para debugging de casos mal clasificados

3. Análisis de Errores:

- Caracterización sistemática de falsos positivos/negativos
- Identificar patrones comunes en errores
- Dirigir recolección de datos futura

5.3.5 Optimización de Despliegue

1. Cuantización de Modelos:

- Cuantización INT8 de MobileNetV2 para edge
- Reducción adicional de tamaño ($\sim 4\times$) y latencia ($\sim 2-3\times$)
- Trade-off: pérdida mínima de accuracy (0.5-1 %)

2. Pruning (Poda):

- Eliminar pesos/neuronas menos importantes
- Reducir modelo sin pérdida significativa de rendimiento

3. Knowledge Distillation:

- Entrenar modelo pequeño (student) con predicciones del grande (teacher)
- Transferir conocimiento de EfficientNetB0 a red más simple
- Objetivo: 95 % accuracy con 1M parámetros

5.4 Impacto Esperado

5.4.1 Impacto Ambiental

La implementación masiva de sistemas de detección automática de polvo puede contribuir significativamente a objetivos de sostenibilidad:

- **Optimización de eficiencia solar:** Maximizar generación de energía limpia
- **Reducción de huella de carbono:** Mayor penetración de renovables en matriz energética
- **Uso eficiente de agua:** Limpieza solo cuando necesaria (crítico en zonas áridas)
- **Prolongación de vida útil:** Mantenimiento predictivo evita degradación prematura

5.4.2 Impacto Económico

- **Reducción de OPEX:** 60-80 % en costos de mantenimiento
- **Aumento de LCOE:** 5-15 % mejora en eficiencia energética
- **Escalabilidad:** Una inversión en IA escala a miles de instalaciones
- **Retorno de inversión:** Típicamente 6-18 meses para plantas grandes

5.4.3 Impacto Tecnológico

Este estudio establece:

- **Benchmark para futuras investigaciones:** Framework replicable y resultados de referencia
- **Democratización de IA:** Código y metodología accesibles para comunidad
- **Transferibilidad:** Framework aplicable a otros dominios (agricultura, infraestructura)
- **Estándar de buenas prácticas:** Protocolo validado de Transfer Learning

5.5 Reflexión Final

Este trabajo demuestra que Transfer Learning con arquitecturas modernas (especialmente ResNet50 y EfficientNetB0) proporciona una solución viable para detección de polvo en paneles solares. La combinación de precisión del 84 %, eficiencia paramétrica (2.2M-8.7M parámetros), y velocidad de inferencia adecuada para aplicaciones bajo demanda posiciona a estos modelos como herramientas útiles para implementación industrial.

El hallazgo más significativo es que no se requieren arquitecturas extremadamente complejas ni datasets masivos para lograr resultados útiles en producción. Con solo $\sim 2,000$ imágenes y aprovechando conocimiento pre-aprendido de ImageNet, es posible alcanzar 79-84 % de accuracy, un nivel de rendimiento adecuado para asistir a inspectores humanos en la identificación de paneles que requieren limpieza.

La transición hacia mantenimiento predictivo habilitado por IA en la industria solar no es una visión futurista, sino una realidad alcanzable hoy con la tecnología presentada en este estudio. La implementación de estos sistemas contribuirá materialmente a la eficiencia y sostenibilidad de la infraestructura energética renovable global, acercándonos a los objetivos de neutralidad de carbono.

Referencias

- [1] hemanthsai7. (2024). *Solar Panel Dust Detection Dataset*. Kaggle.
<https://www.kaggle.com/datasets/hemanthsai7/solar-panel-dust-detection>
Consultado: Febrero 2026